Stage1 - Week2

Target

- ZIP基础结构学习，掌握ZIP的结构与解析流程；

Detailed

1. Zip基础结构，及其解析流程
2. 标准解析模式与流式解析模式的区别
3. Zip进阶结构：加密、Zip64

Deliverables

- ZIP文件结构图示
- ZIP文件解析流程

Content

ZIP文件基础结构图示

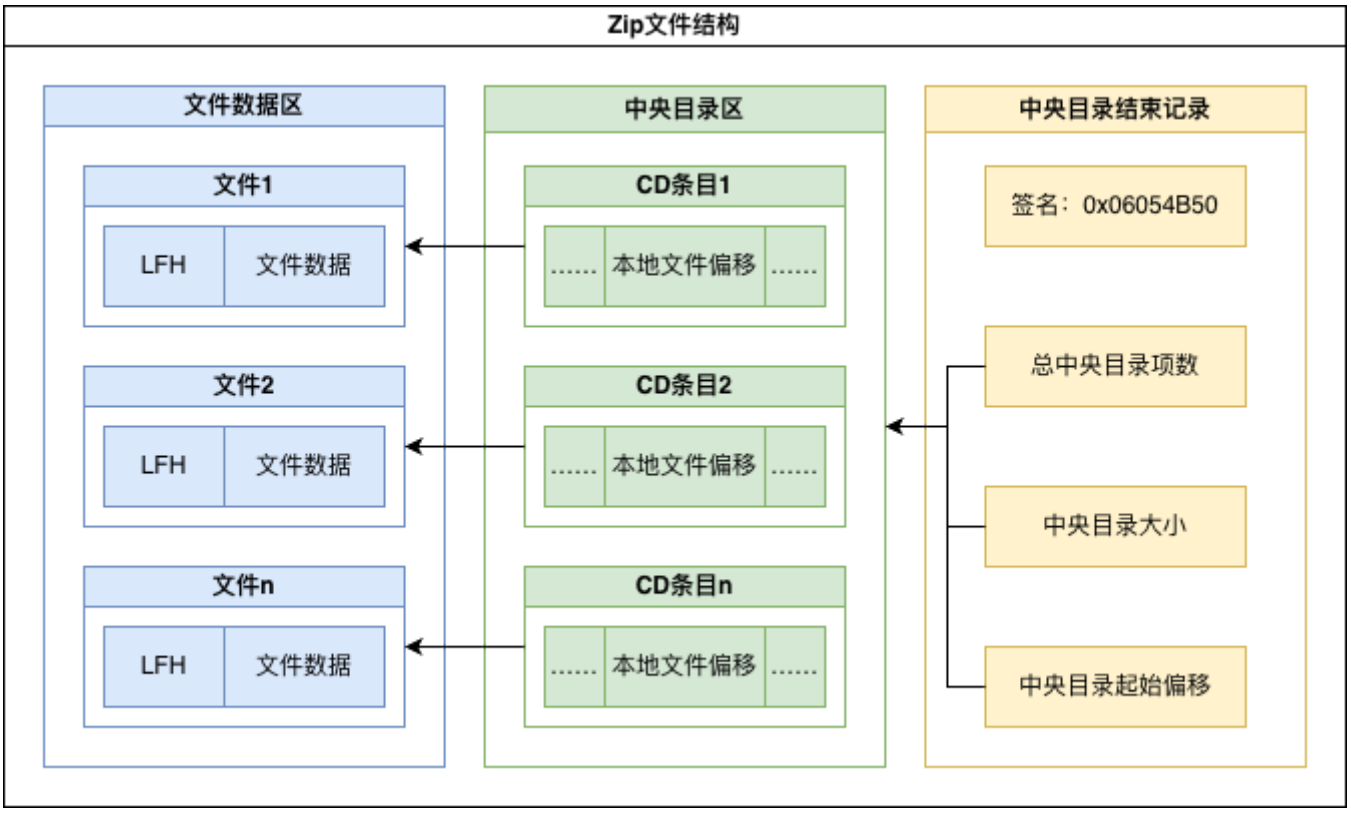

ZIP文件主要由三部分构成:

1. Local File Header: 每个压缩文件的起始位置，包含文件的元数据信息；
2. Central Directory(CD): 压缩文件的目录，记录了所有文件的元数据信息；
3. End of Central Directory(EOCDR): 压缩文件的结束位置，包含目录的元数据信息。

只考虑非分卷压缩的情况，EOCDR中包含指向Central Directory的偏移量，Central Directory的大小，以及CD条目的项数。

中央目录区包含了所有文件的元数据信息，每个文件的元数据信息由一个Central Directory Entry(CD Entry)表示。每个CD项中含有指向对应Local File Header的偏移量。

本地文件头区包含了每个压缩文件的元数据信息，每个文件的元数据信息由一个Local File Header(LFH)表示。文件的实际数据(压缩或未压缩)紧跟在其对应的LFH后面。

ZIP文件解析流程

本地文件头区已经包含了每个压缩文件的元数据信息，理论上仅通过读取LFH就能解压出压缩包内的所有文件，因此在解析ZIP文件时就产生了两种解析方式。

- 标准解析模式: 先读取整个Central Directory，然后根据CD项中的偏移量，随机访问到对应文件的LFH，从而获取文件的元数据信息。
- 流式解析模式: 从Local File Header开始，顺序解析每个压缩文件的元数据信息，直到无法读取有效的LFH签名为止。

目前大多数ZIP解析器默认采用标准解析模式，忽略掉没有被CD条目指向的LFH。

标准解析模式

从EOCDR中获取指向Central Directory的偏移量，然后根据CD项中的偏移量，随机访问到对应文件的LFH，从而获取文件的元数据信息。

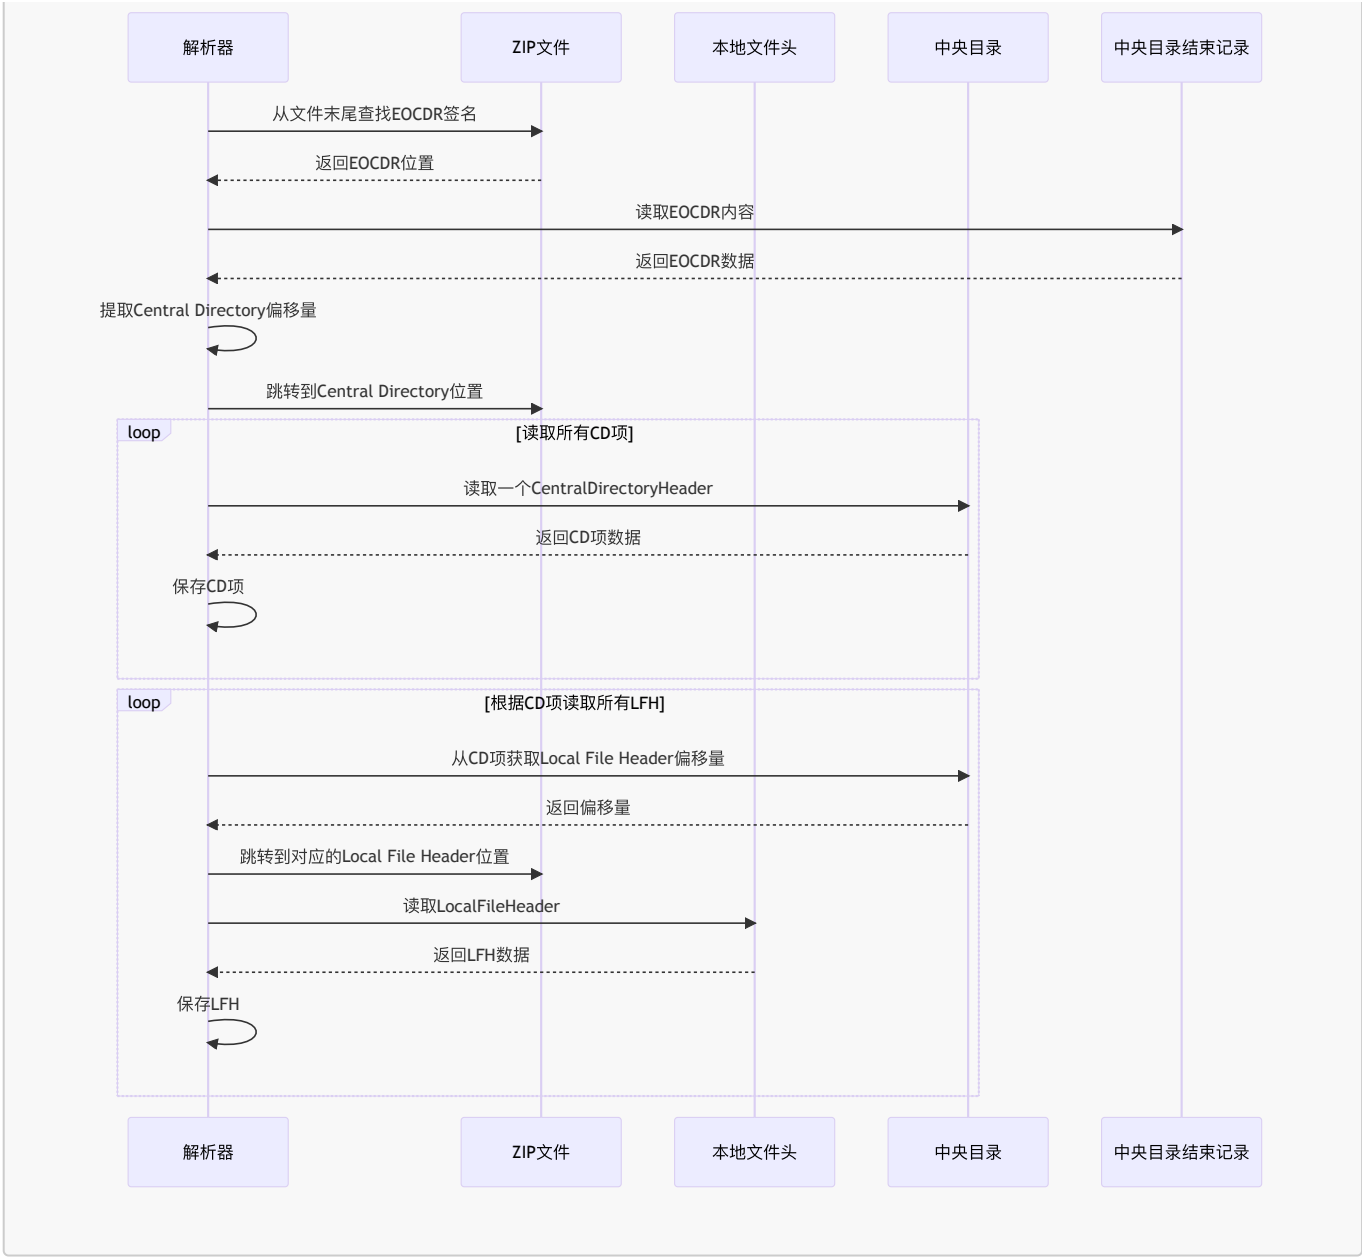

流式解析模式

从Local File Header开始，顺序解析每个压缩文件的元数据信息，直到无法读取有效的LFH签名为止。

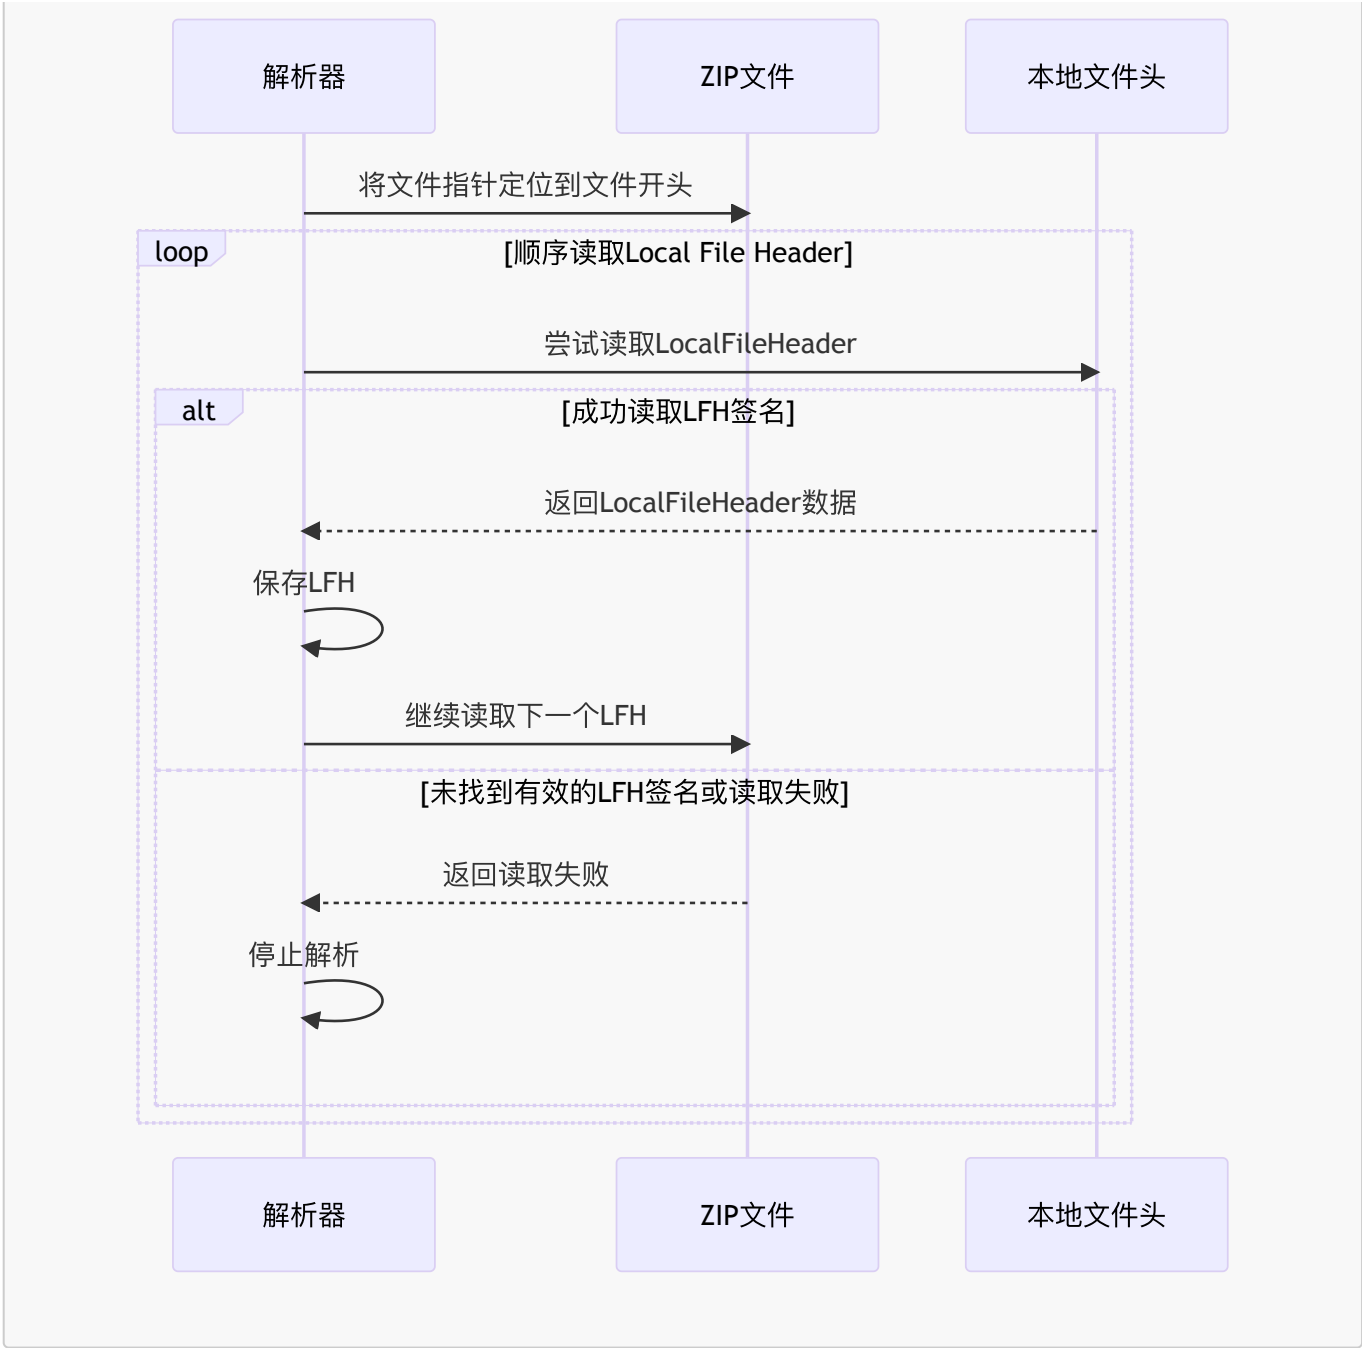

手工篡改ZIP进行实验

`zip_analyze`目录为一个Zip解析器实例，可以使用两种解析模式读取未加密的Zip文件结构。另外该目录下包含两个Zip文件，分别为`zip_demo.zip`和`zip_demo_hacked.zip`。两者的区别在于`zip_demo_hacked.zip`在`zip_demo.zip`的基础上，在LFH区添加了一个额外的文件`hacked.txt`对应的LFH及其数据。具体如下图所示：

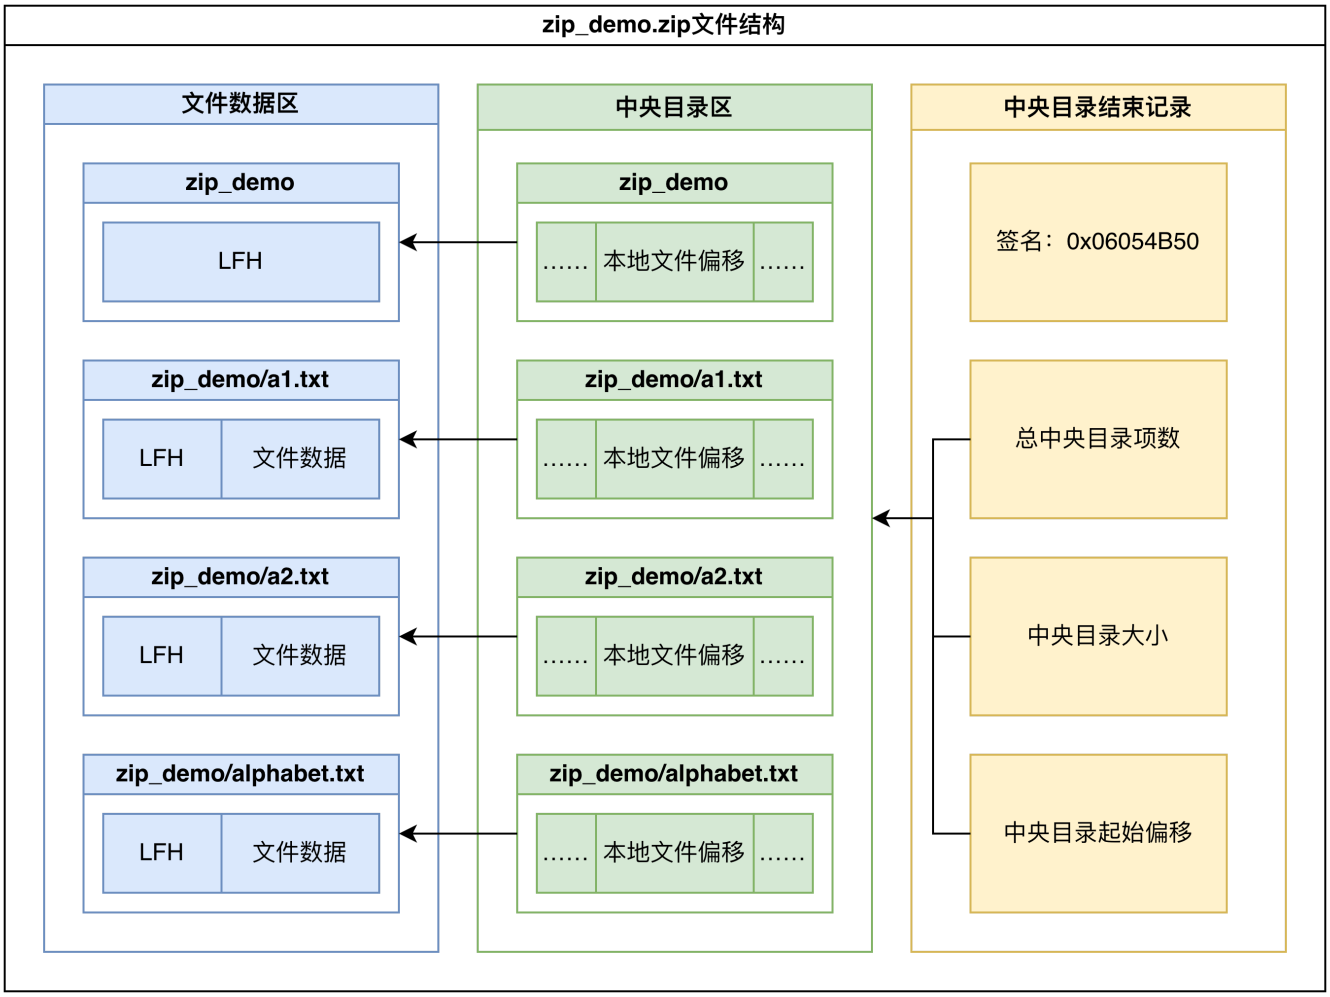
zip_demo.zip文件结构
文件数据区
中央目录区
中央目录结束记录
zip_demo
LFH
zip_demo
..... 本地文件偏移 .....
签名：0x06054B50
zip_demo/a1.txt
LFH 文件数据
zip_demo/a1.txt
..... 本地文件偏移 .....
总中央目录项数
zip_demo/a2.txt
LFH 文件数据
zip_demo/a2.txt
..... 本地文件偏移 .....
中央目录大小
zip_demo/alphabet.txt
LFH 文件数据
zip_demo/alphabet.txt
..... 本地文件偏移 .....
中央目录起始偏移

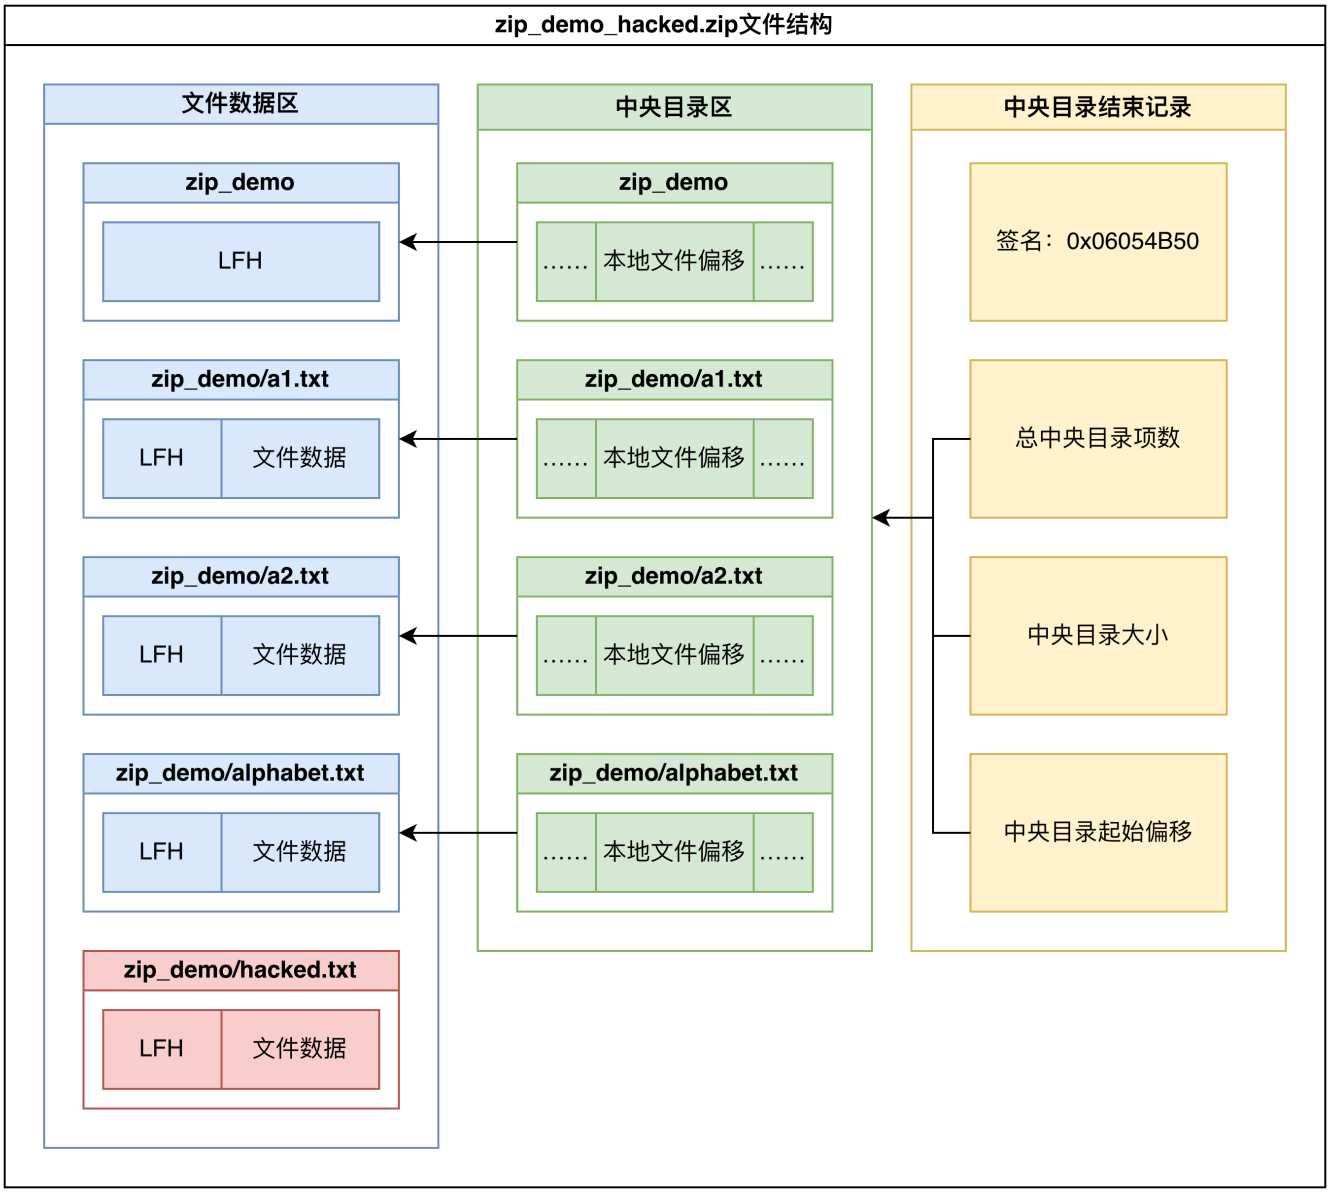

使用`zip_analyze`解析`zip_demo_hacked.zip`文件，在标准解析模式下，`zip_analyze`忽略掉了仅在LFH中存在的`hacked.txt`文件；而在流式解析模式下，`zip_analyze`能够成功解析出`hacked.txt`文件的信息。

Zip文件具体分析

根据官方文档, Zip文件的结构如下:

```
[local file header 1]
[encryption header 1]
[file data 1]
[data descriptor 1]
.
.
.
[local file header n]
[encryption header n]
[file data n]
[data descriptor n]
[archive decryption header]
```

```
[archive extra data record]
[central directory header 1]
.
.
.
[central directory header n]
[zip64 end of central directory record]
[zip64 end of central directory locator]
[end of central directory record]
```

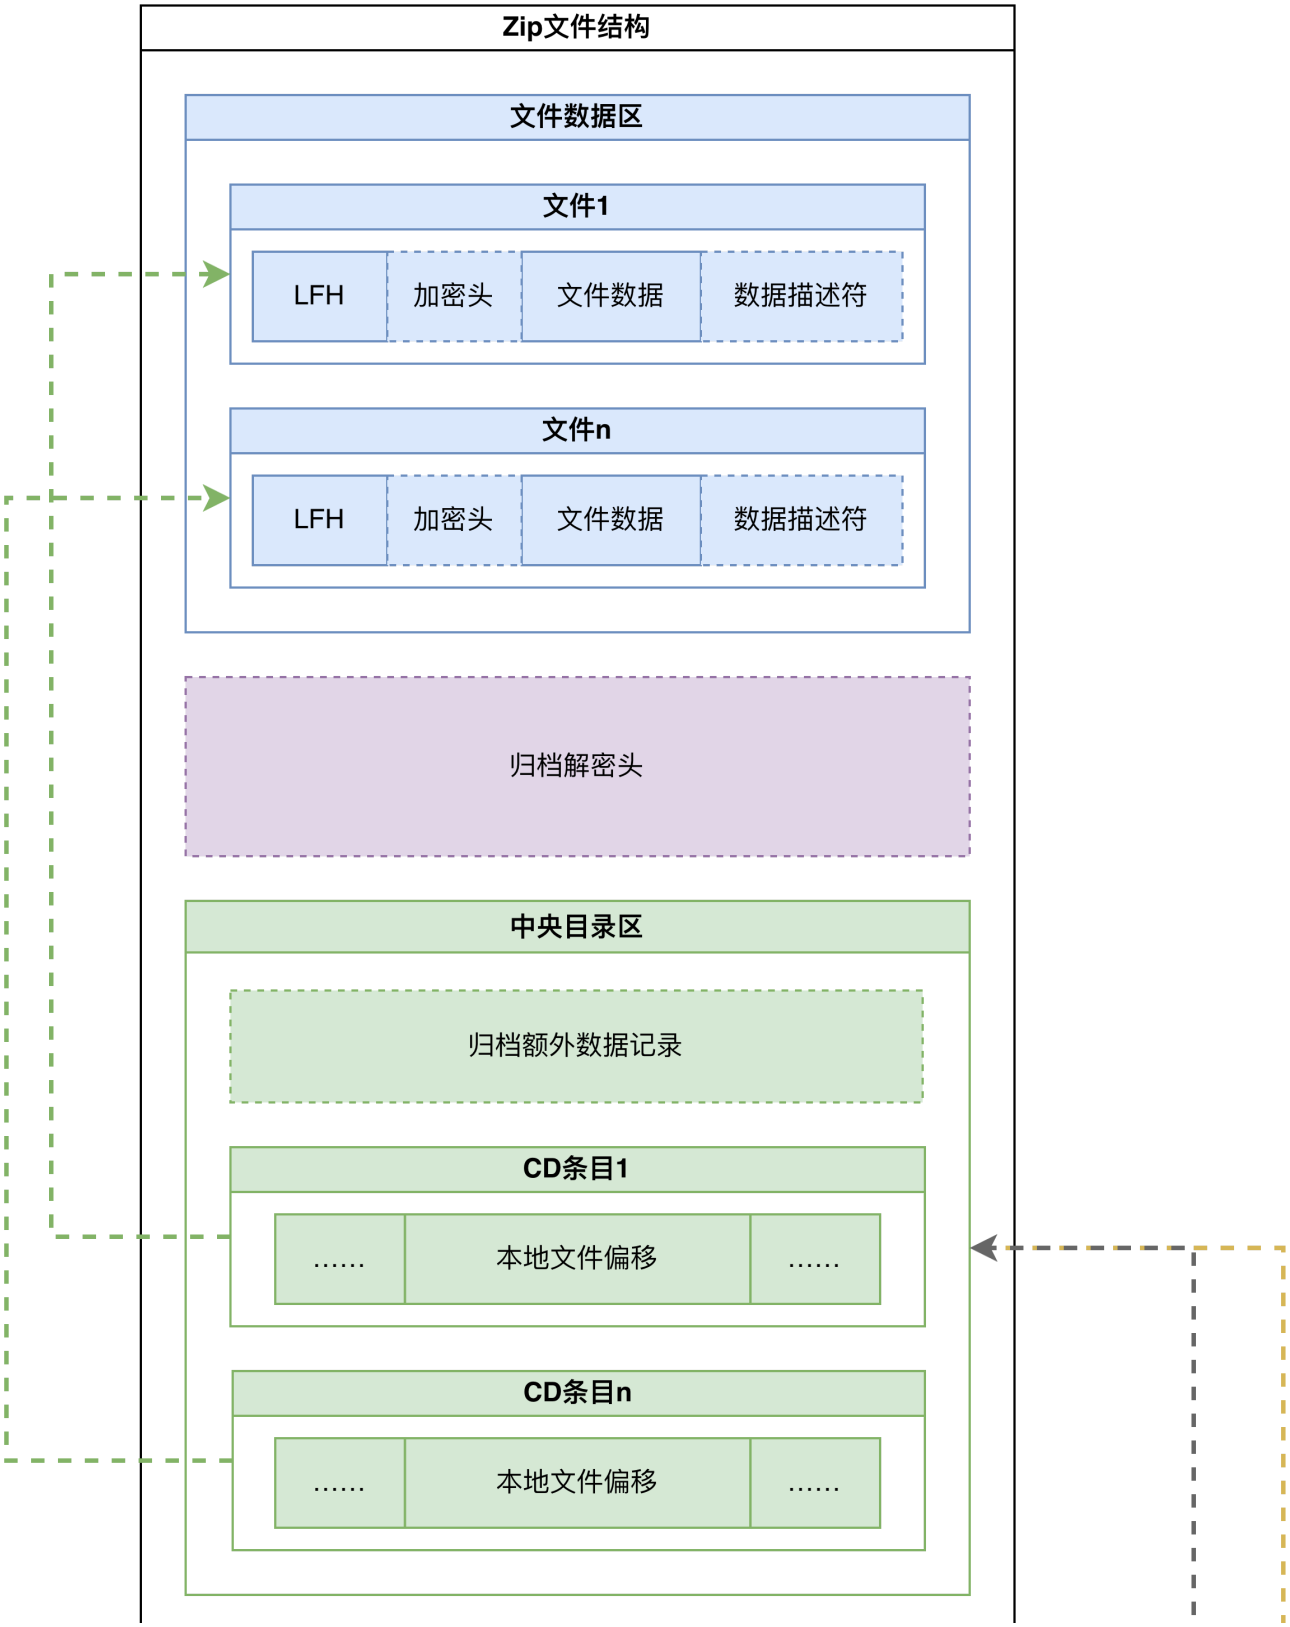

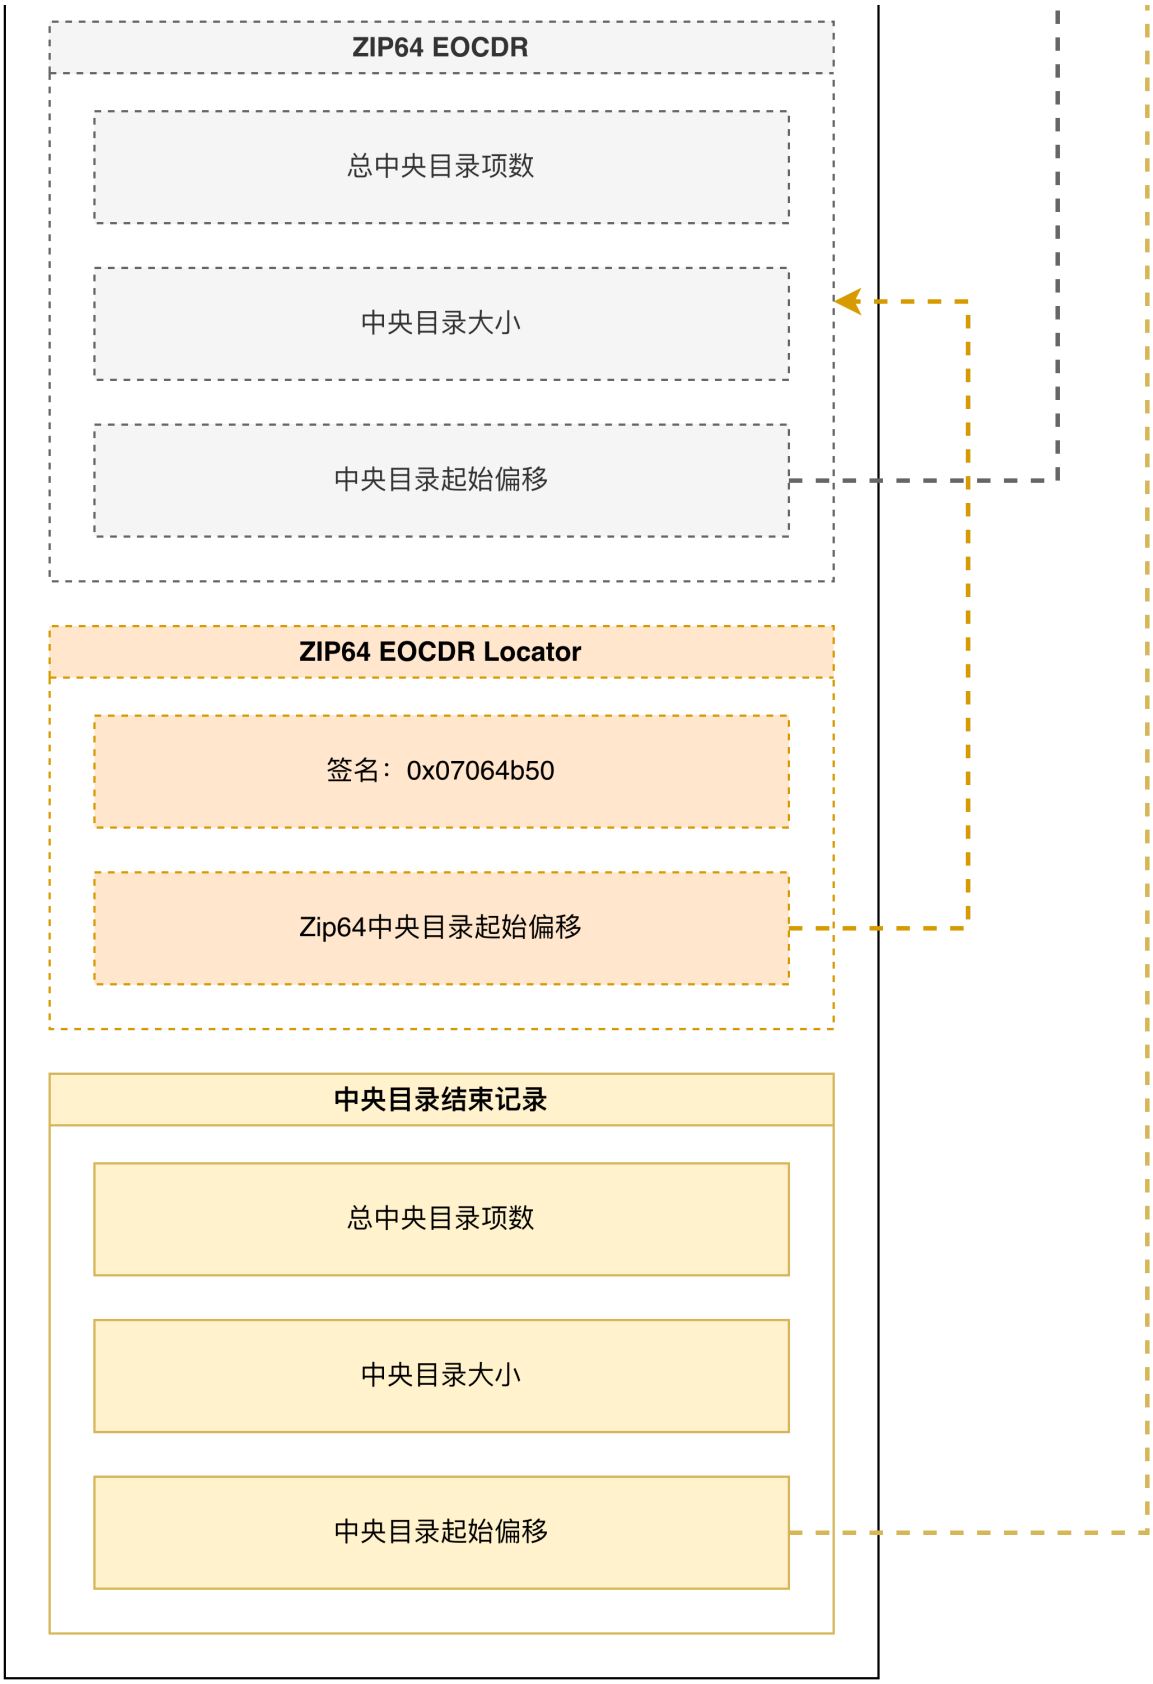

本地文件头 - Local File Header

```
uint32_t signature;
uint16_t version_needed;
uint16_t general_bit_flag;
uint16_t compression_method;
```

```
    uint16_t last_mod_time;
    uint16_t last_mod_date;
    uint32_t crc32;
    uint32_t compressed_size;
    uint32_t uncompressed_size;
    uint16_t filename_length;
    uint16_t extra_field_length;
    std::string filename;
    std::unique_ptr<uint8_t[]> extra_field;
```

本地文件头的extra_field没有固定的内容，不同的压缩器可能会在extra_field中添加不同的信息。但是在extra_field中添加信息时通常要遵循统一的结构: 标签 - 长度 - 数据。

- Tag（2 字节）：标识该扩展块的类型（如操作系统相关信息、压缩算法扩展等）。
- Length（2 字节）：表示后续数据的长度。
- Data：具体的扩展数据，格式由 Tag 定义。

具体标签值和含义的映射可以参考官方文档的4.5.2节，其中列举了由PKWARE定义的标签值和含义。

general_bit_flag

加密头 - Encryption Header

是否存在: 仅当`general_bit_flag`的第0位为1时，才存在加密头。

加密头的具体长度与结构由`general_bit_flag`的第6位确定：

- 当第六位为0时，加密头格式为传统PKWARE加密格式，长度为12字节；
- 当第六位为1时，加密头格式强加密格式，长度为可变，至少30字节。

```
IVSize    2 bytes  - 初始化向量大小
IVData    IVSize   - 初始化向量数据
Size      4 bytes  - 剩余解密头数据大小
Format    2 bytes  - 格式定义 (当前必须为3)
AlgID     2 bytes  - 加密算法标识符
Bitlen    2 bytes  - 密钥长度 (32-448 bits)
Flags     2 bytes  - 处理标志
ErdSize   2 bytes  - 加密随机数据大小
ErdData   ErdSize  - 加密的随机数据
Reserved1 4 bytes  - 证书处理保留字段
Reserved2 (var)    - 证书处理保留字段
VSize     2 bytes  - 密码验证数据大小
VData     VSize-4  - 密码验证数据 (加密)
VCRC32    4 bytes  - 密码验证数据的CRC32 (加密)
```

校验密码是否正确即是通过加密头内的部分字段进行的。

数据描述符 - Data Descriptor

用于在流式压缩场景下，将压缩数据的CRC-32、压缩大小和未压缩大小等信息从文件数据中分离出来。

由于lfh在文件数据之前，因此在流式压缩场景下，无法提前确定lfh中的crc32, compressed_size和uncompressed_size字段。此时，需要在文件数据之后添加一个数据描述符，用于存储这些信息。

```
    uint32_t signature;             /* 0x08074b50 */
    uint32_t crc32;
    uint32_t compressed_size;
    uint32_t uncompressed_size;
```

归档解密头 - Archive Decryption Header

结构与加密头相同，不同的是加密头是在每个文件数据之前，而归档解密头是在所有文件数据之后。归档解密头的位置由Zip64 End of Central Directory Record中的Start of Central Directory字段指定。

使用归档解密头可以支持加密整个中央目录结构，保护所有文件的元数据。

只在Zip64格式下才会存在归档解密头。

归档解密头的结构与Encryption Header完全相同。

归档额外数据记录 - Archive Extra Data Record

Archive Extra Data Record 主要用于存储与中央目录加密相关的额外信息，特别是：

- 数字证书信息：存储 PKCS#7 证书存储、X.509 证书 ID 和签名等
- 加密相关数据：存储加密接收者证书列表等

其结构定义如下：

```
    uint32_t signature;             /* 0x08074b50 */
    uint32_t extra_field_length;
    std::unique_ptr<uint8_t[]> extra_field;
```

中央目录头 - Central Directory Header

```
    uint32_t signature;
    uint16_t version_made_by;
    uint16_t version_needed;
    uint16_t general_bit_flag;
    uint16_t compression_method;
    uint16_t last_mod_time;
    uint16_t last_mod_date;
    uint32_t crc32;
    uint32_t compressed_size;
    uint32_t uncompressed_size;
    uint16_t filename_length;
```

```
    uint16_t extra_field_length;
    uint16_t file_comment_length;
    uint16_t disk_number_start;
    uint16_t internal_attr;
    uint32_t external_attr;
    uint32_t local_header_offset;
    std::string filename;
    std::unique_ptr<uint8_t[]> extra_field;
    std::string file_comment;
```

中央目录头与本地文件头之间存在许多冗余字段，原则上相对应的一对中央目录头和本地文件头，表示含义相同的字段值应该是相同的。

相关流程

Zip64解析流程

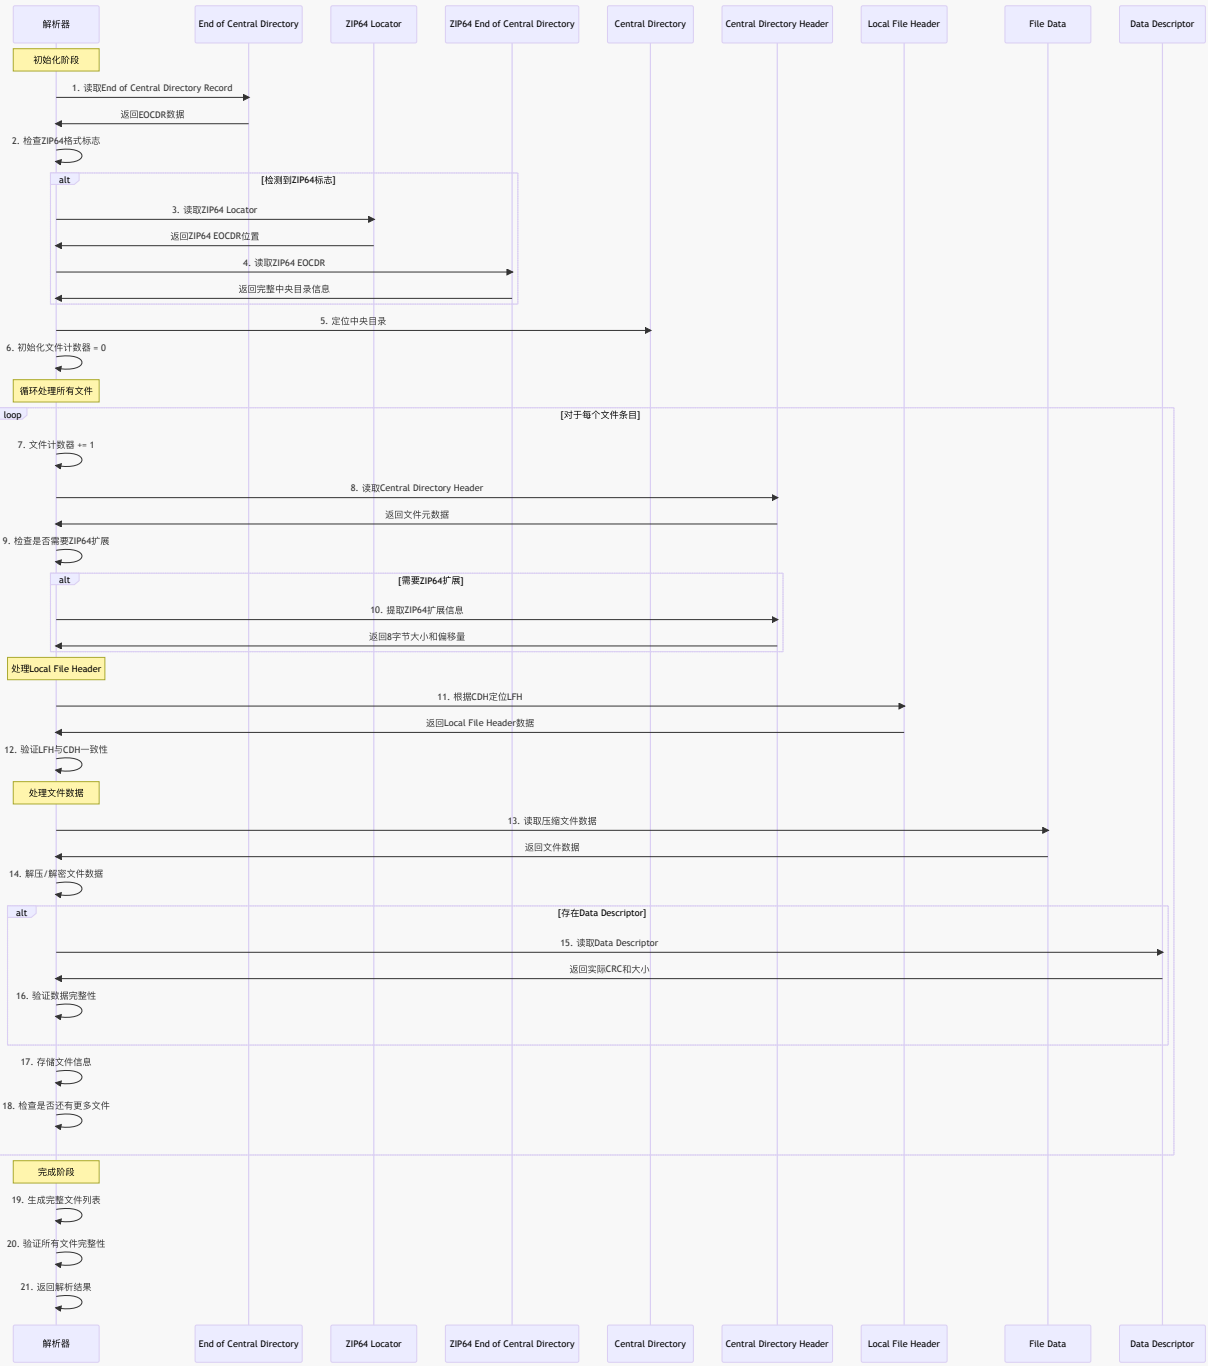

启用中央目录加密时的解析流程

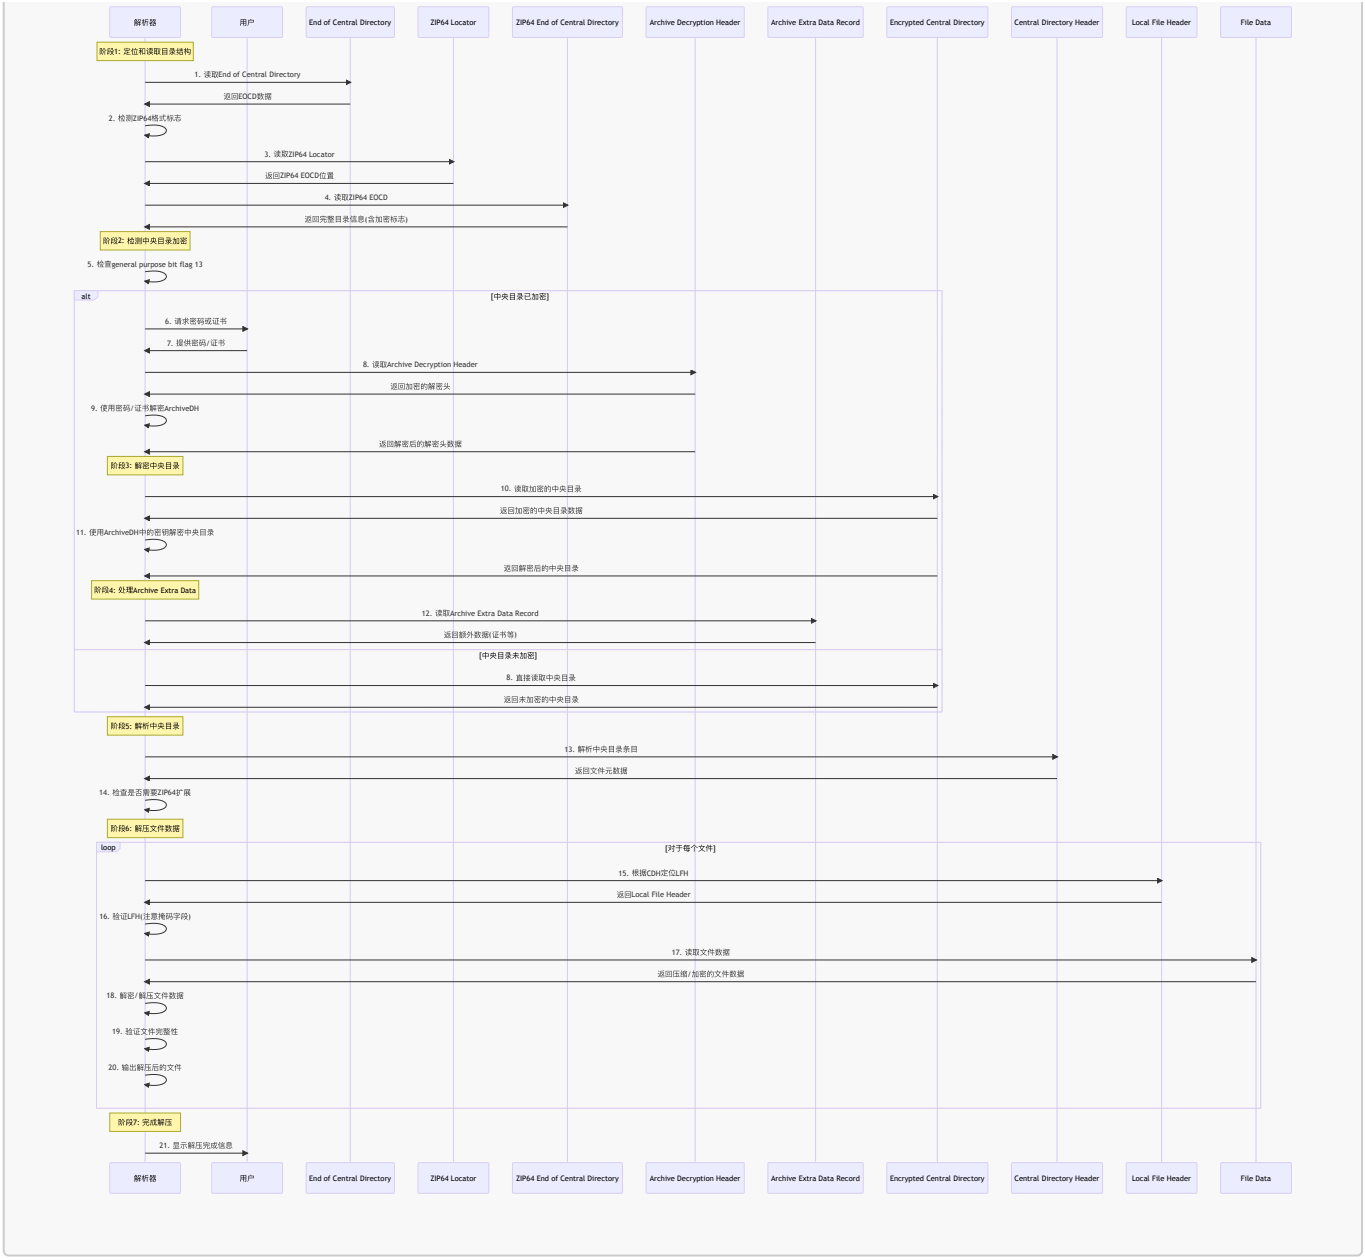

校验密码是否正确

传统PKWARE加密格式校验密码

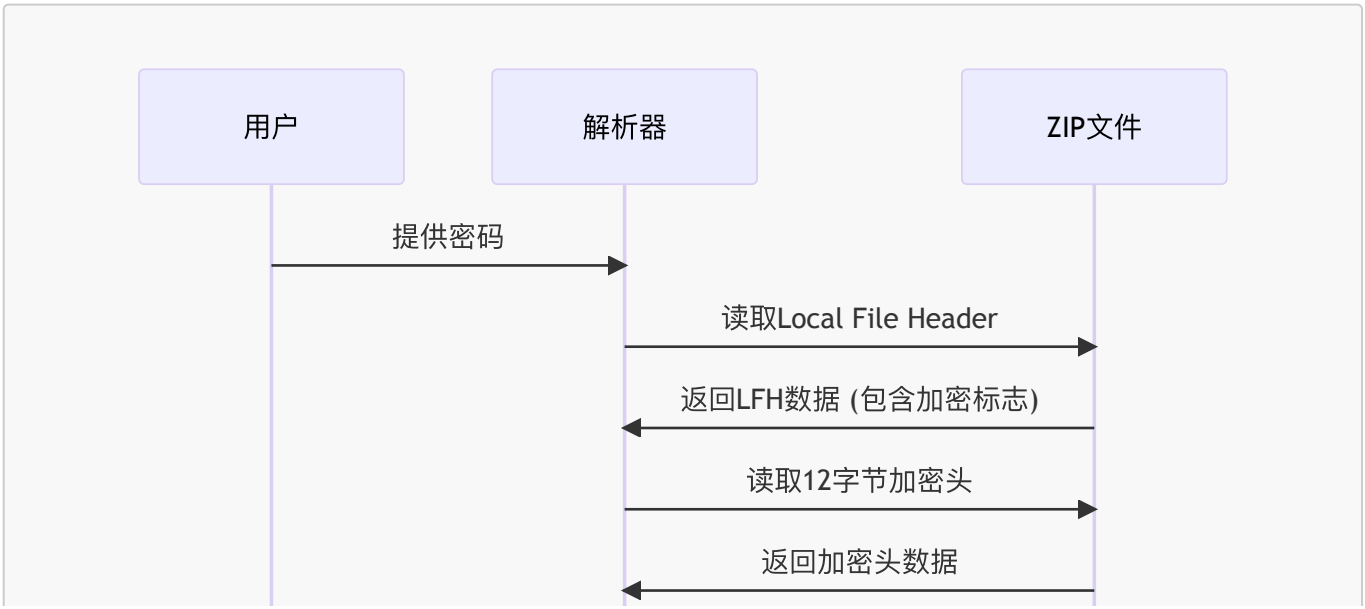

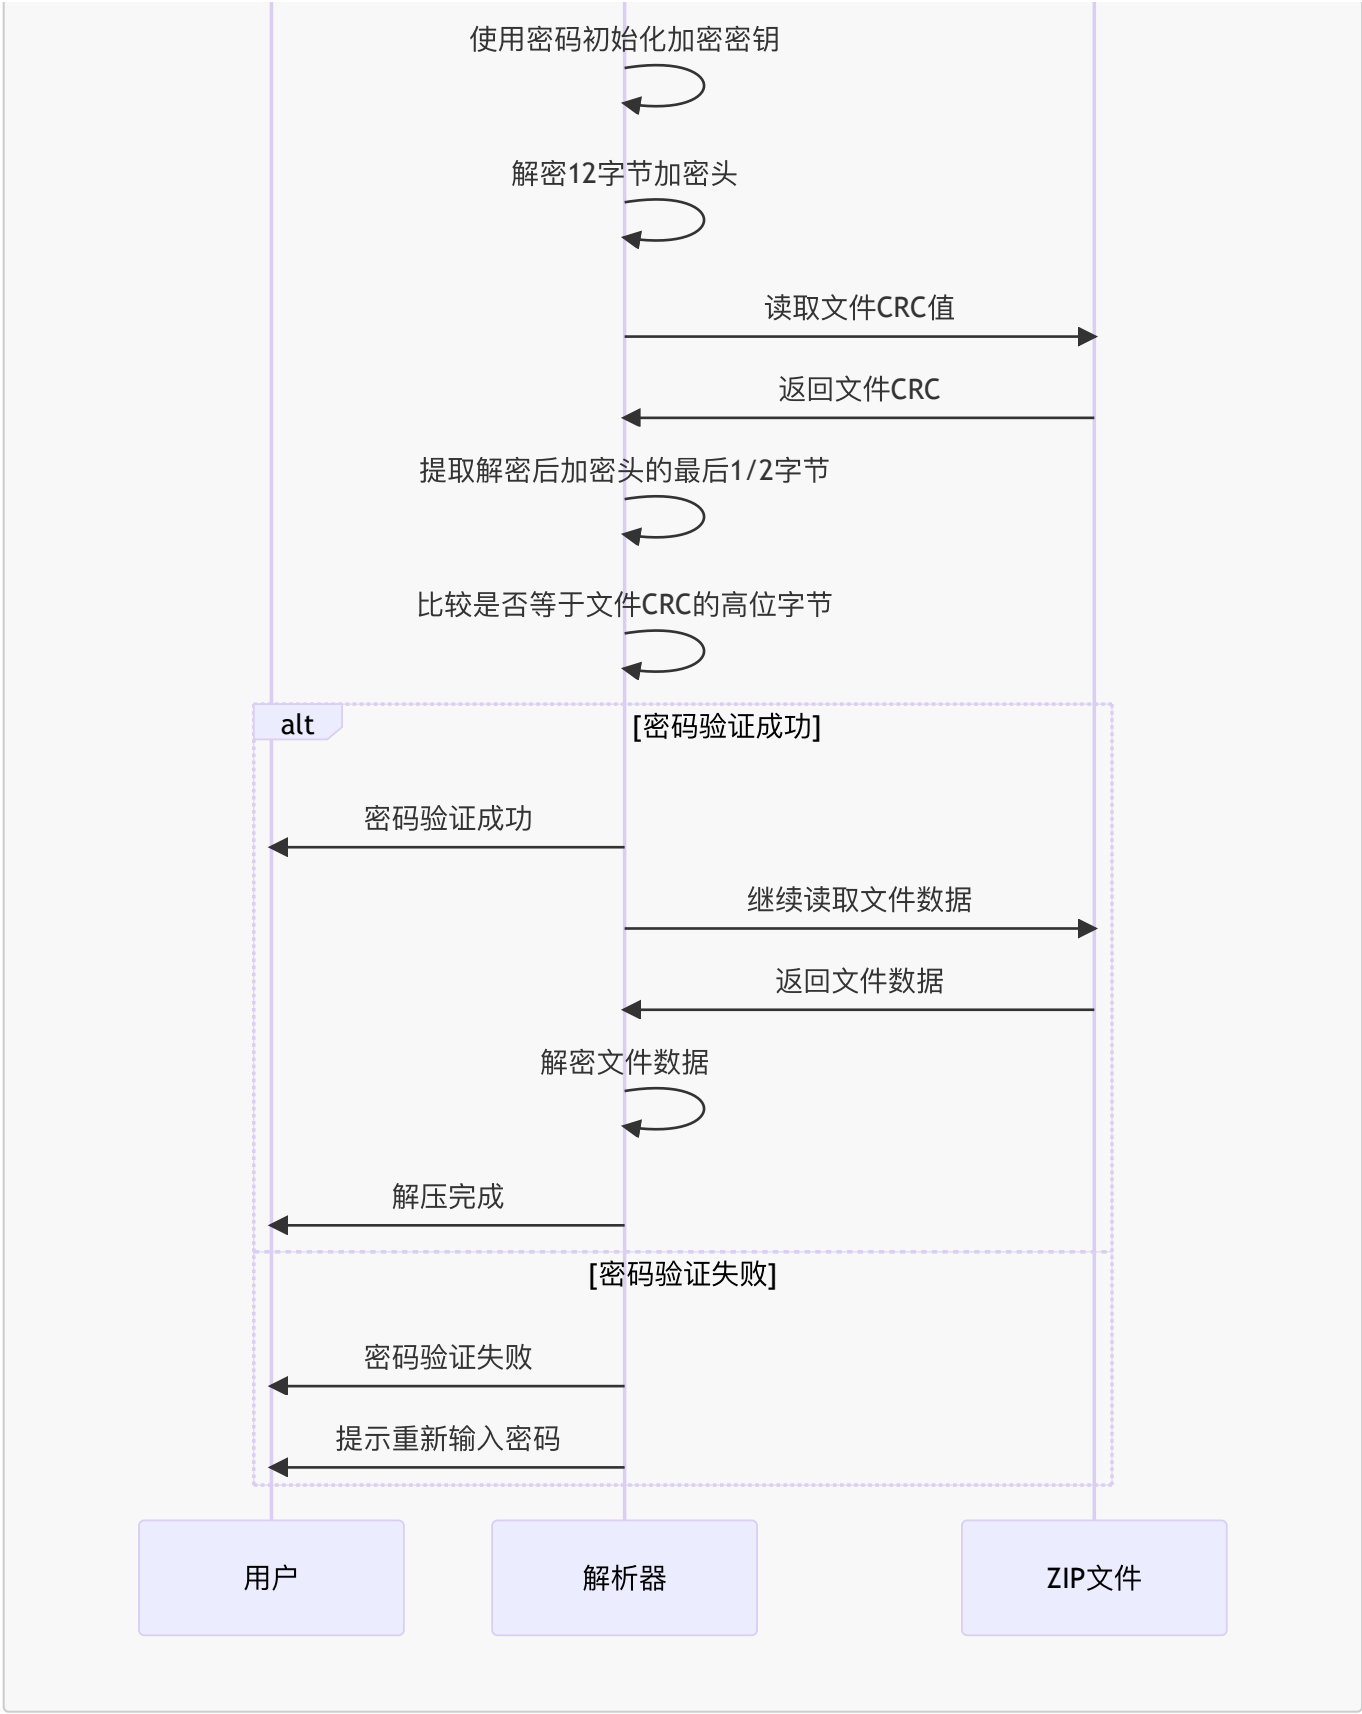
使用密码初始化加密密钥
解密12字节加密头
读取文件CRC值
返回文件CRC
提取解密后加密头的最后1/2字节
比较是否等于文件CRC的高位字节
alt
[密码验证成功]
密码验证成功
继续读取文件数据
返回文件数据
解密文件数据
解压完成
[密码验证失败]
密码验证失败
提示重新输入密码
用户
解析器
ZIP文件

强加密

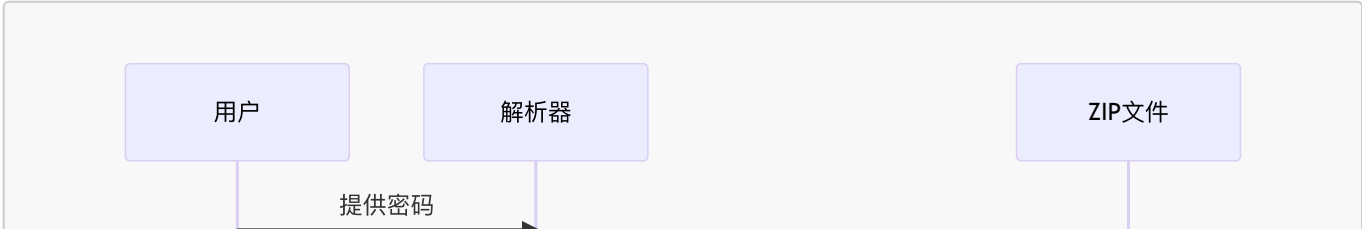
用户
解析器
ZIP文件
提供密码

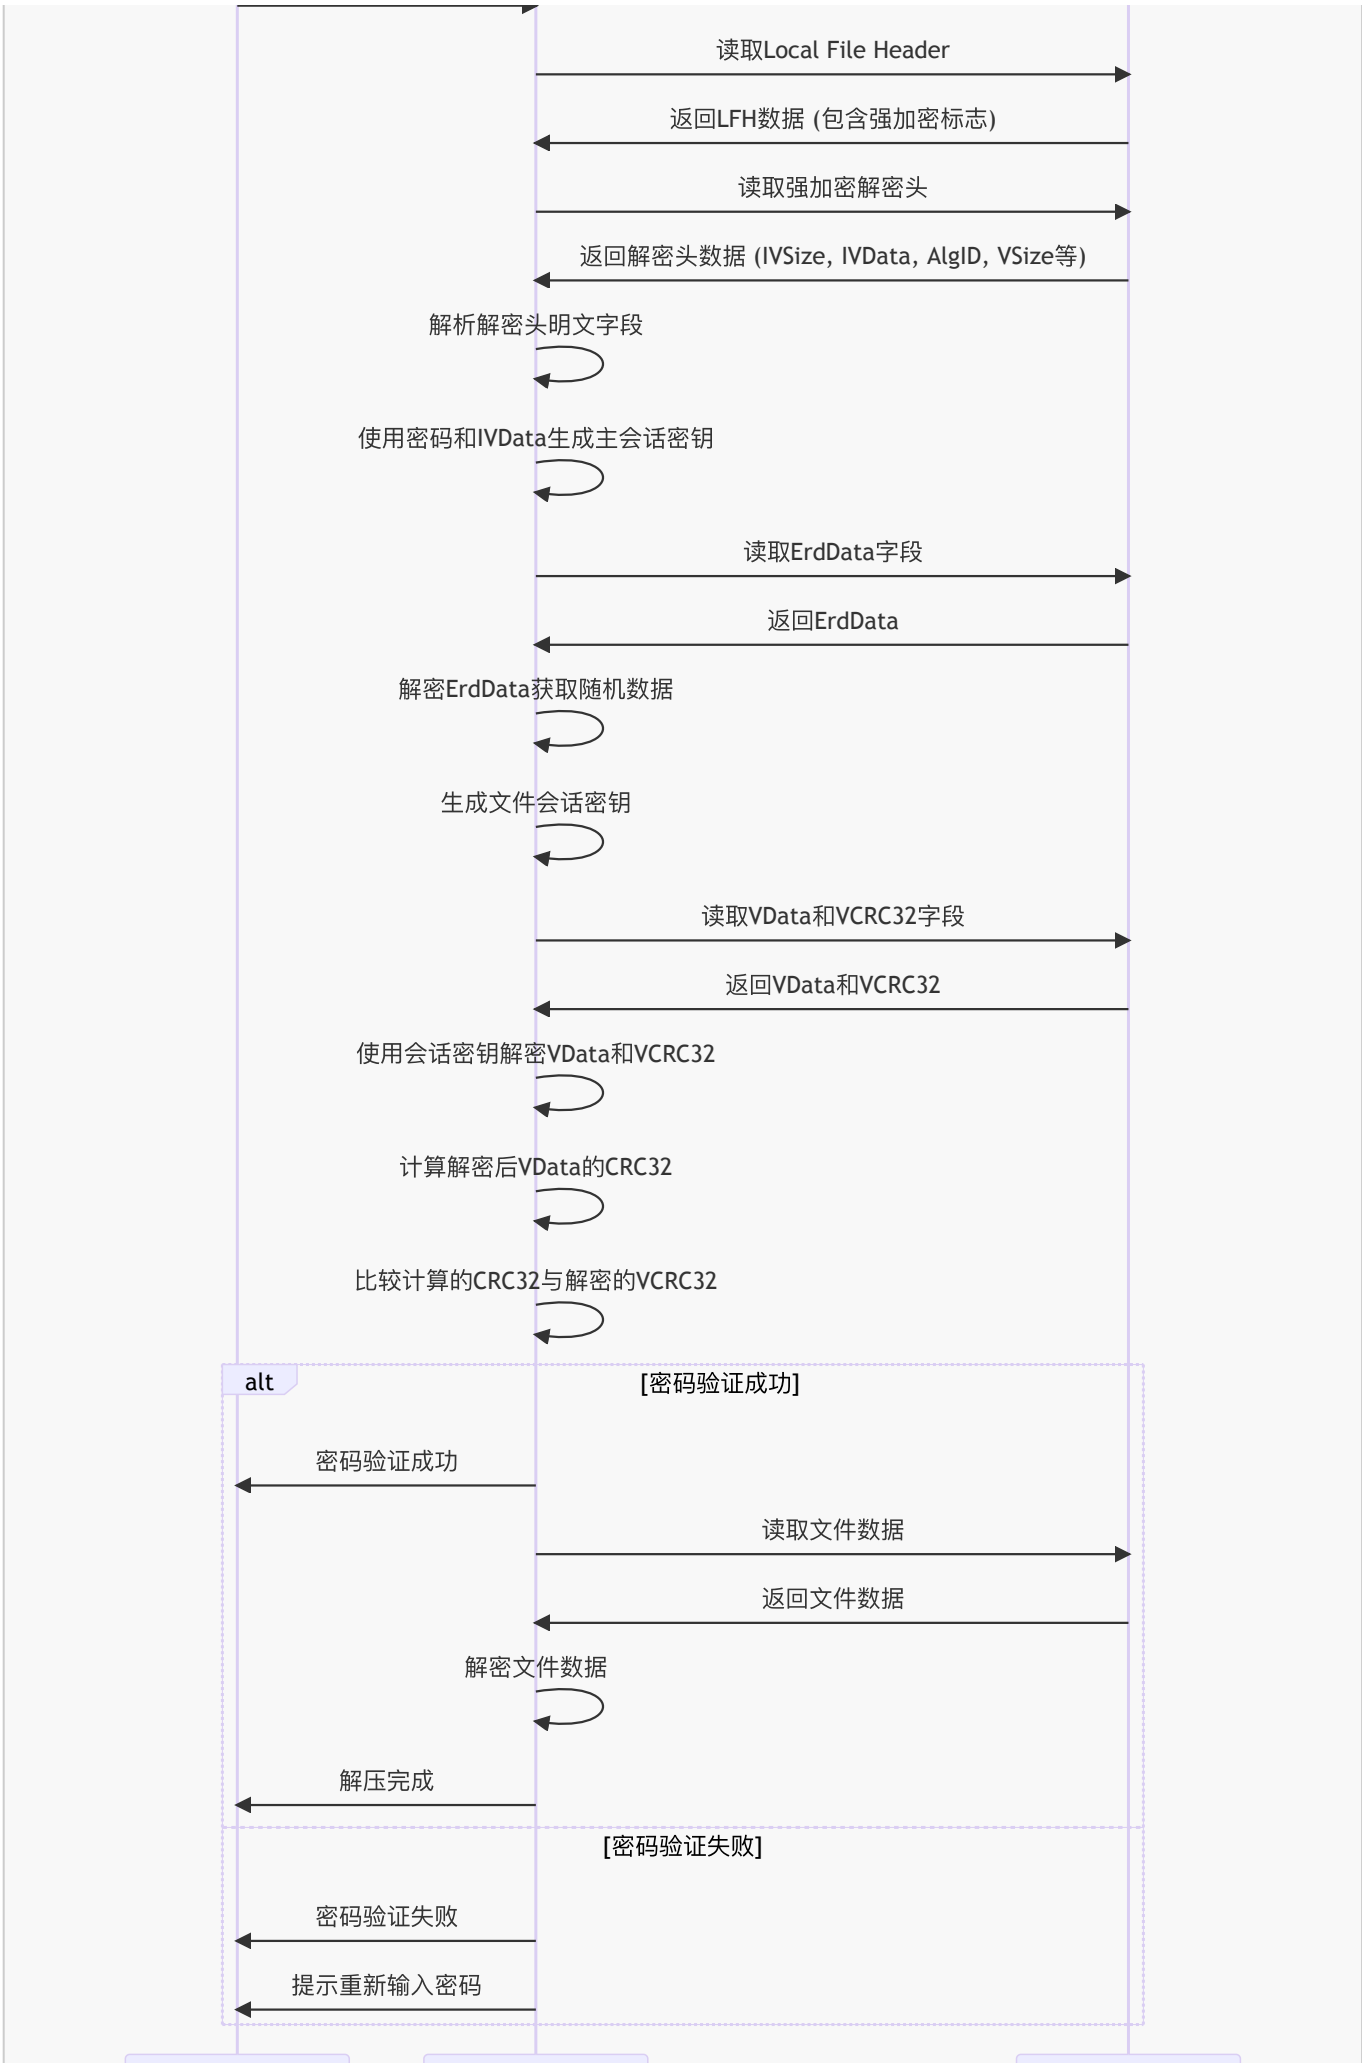
读取Local File Header
返回LFH数据 (包含强加密标志)
读取强加密解密头
返回解密头数据 (IVSize, IVData, AlgID, VSize等)
解析解密头明文字段
使用密码和IVData生成主会话密钥
读取ErdData字段
返回ErdData
解密ErdData获取随机数据
生成文件会话密钥
读取VData和VCRC32字段
返回VData和VCRC32
使用会话密钥解密VData和VCRC32
计算解密后VData的CRC32
比较计算的CRC32与解密的VCRC32
alt
[密码验证成功]
密码验证成功
读取文件数据
返回文件数据
解密文件数据
解压完成
[密码验证失败]
密码验证失败
提示重新输入密码


用户
解析器
ZIP文件

启用中央目录加密

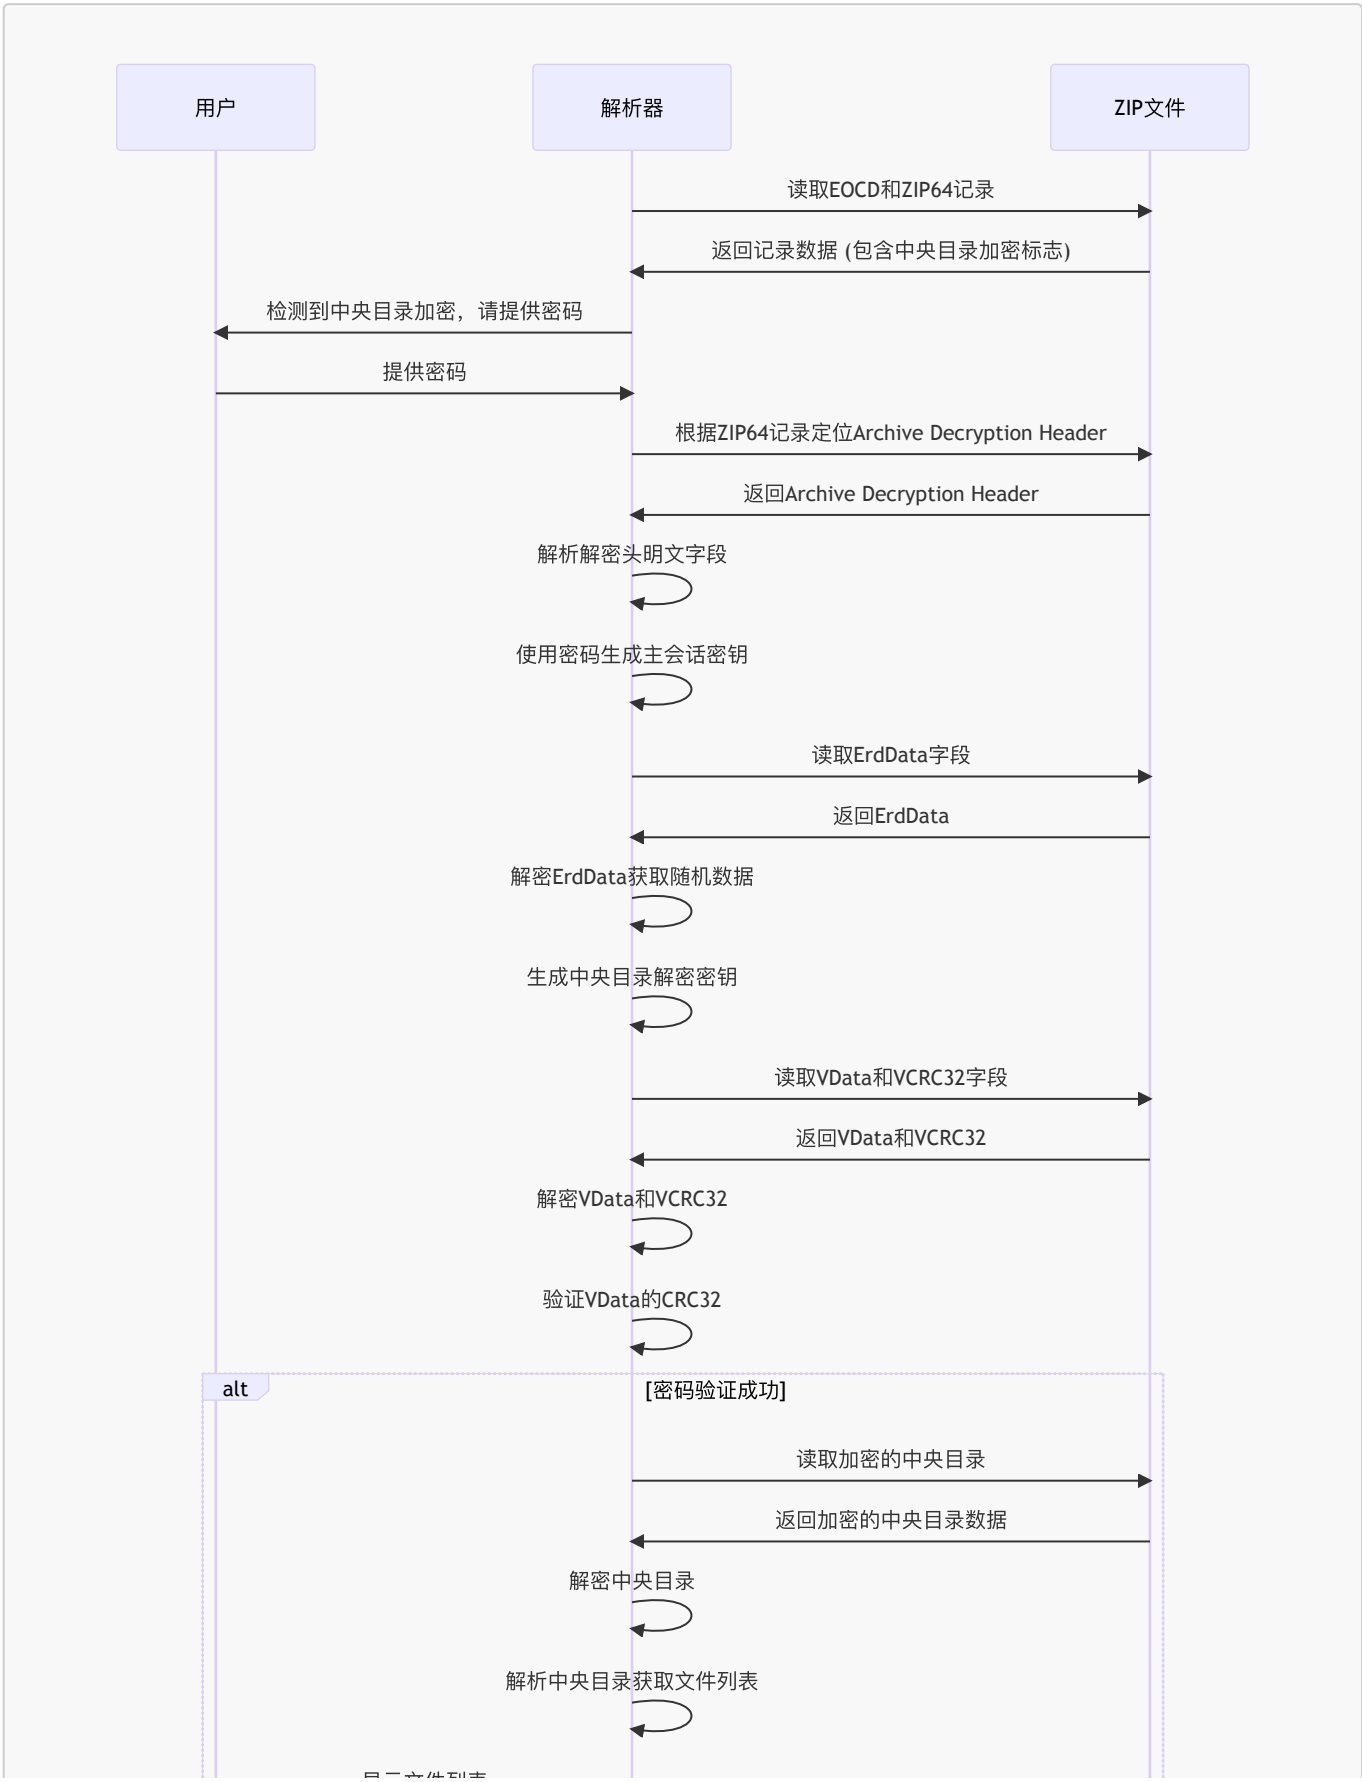
用户
解析器
ZIP文件
读取EOCD和ZIP64记录
返回记录数据 (包含中央目录加密标志)
检测到中央目录加密，请提供密码
提供密码
根据ZIP64记录定位Archive Decryption Header
返回Archive Decryption Header
解析解密头明文字段
使用密码生成主会话密钥
读取ErdData字段
返回ErdData
解密ErdData获取随机数据
生成中央目录解密密钥
读取VData和VCRC32字段
返回VData和VCRC32
解密VData和VCRC32
验证VData的CRC32
alt
[密码验证成功]
读取加密的中央目录
返回加密的中央目录数据
解密中央目录
解析中央目录获取文件列表

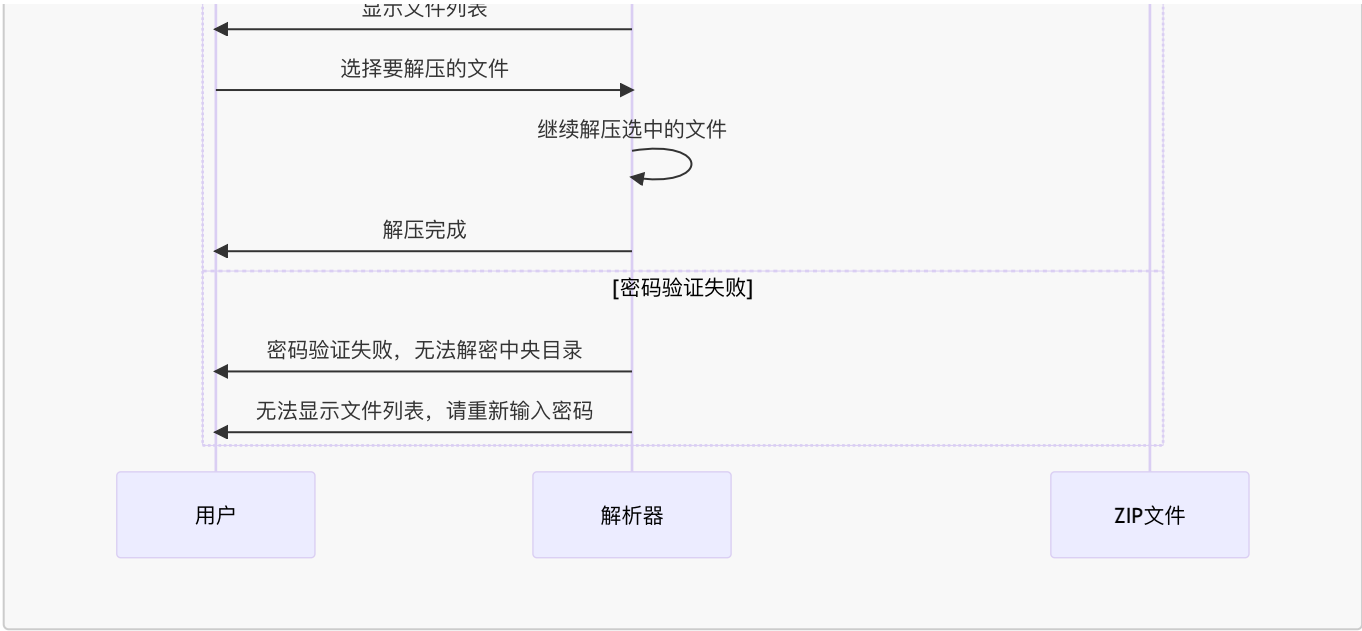

Questions

- 考虑加密和Zip64的情况下，Zip文件结构会复杂很多，在后续工作中需要偏向考虑这两种case嘛?
- 标准解析模式下，从文件尾部搜索EOCDR时，如果EOCDR中的extra field中如果出现一个完整的EOCDR，解析器会如何处理?